

手法ガイド — 使った方法を理解して説明するために

本研究で使った解析手法を、理解して自分の口で説明できることを目標に、1つずつ解説する。各手法は「何のため／直感（比喩）／式の意味／本研究での使いどころ／発表で聞かれたら」。

手法は問題が出るたびに一段ずつ足された。だからまず「どの手法がどの問題を解いたか」をつかむと全体が腑に落ちる。

0. 手法と、それが解いた問題（地図）

#	手法	解いた問題
1	エントロピー / 相互情報量	「2変数がどれだけ関係するか」を測る
2	Transfer Entropy	関係の向き（どちらが原因か）を測る
3	サロゲート・順列検定	それは偶然でないか
4	多重比較補正	たくさん検定すると増える偽陽性を抑える
5	Miller-Madow / KNN 推定	ヒストグラム推定のバイアスを直す
6	条件付き相互情報量	共通原因を差し引いて本当の関係を見る
7	PCMCi	全変数を考慮した多変量の因果を描く
8	PID（部分情報分解）	共有情報を冗長／固有／相乗に分ける
9	相互作用情報 / O-information	測度によらず・系全体で相乗を測る
10	Spearman 相関	結合の強さと気候の単調な関係を測る

1. エントロピーと相互情報量 — 「関係の量」を測る

何のため：2つの変数がどれだけ一緒に動くか（＝共有する情報）を、非線形も含めて測る。

直感：エントロピー $H(X)$ は「 X の不確かさ・情報量」。相互情報量 $I(X;Y)$ は「 Y を知ると X の不確かさがどれだけ減るか」＝ 2 変数が共有する情報。相関係数の”非線形も捉える版”と思ってよい。

式の意味： $-H(X) = -\sum p(x) \log p(x) \cdots$ 起こりにくいことほど情報が大きい、を平均。 $-I(X;Y) = H(X) + H(Y) - H(X,Y) \cdots$ 「別々の不確かさの和」から「一緒にした不確かさ」を引く。独立なら $H(X,Y)=H(X)+H(Y)$ で $I=0$ 。関係が強いほど I が大きい。

本研究：すべての土台。「見かけの結合の強さ」は I で測っている（図2の縦軸など）。

聞かれたら：「相互情報量は、2変数が共有する情報の量。相関の非線形版で、独立なら 0 です。」

2. 条件付き相互情報量 — 「第3の変数を差し引く」

何のため：「X と Y が関係する」のが、別の変数 Z のせいかを調べる。

直感： $I(X;Y|Z)$ は「Z を既に知った上で、なお X と Y が共有する情報」。Z が両者を動かしているだけなら、Z を知れば X-Y の関係は消える ($I(X;Y|Z) \approx 0$)。

式： $I(X;Y|Z) = H(X,Z) + H(Y,Z) - H(Z) - H(X,Y,Z)$ 。

本研究：放射 Rg を Z にして $I(X;Y|Rg)$ を計算 → 見かけの結合が共通駆動の影かを判定 (図2b)。

聞かれたら：「Z を差し引いても残る X-Y の関係。共通原因の影を除くのに使います。」

3. Transfer Entropy — 「情報の流れの向き」

何のため：相互情報量は対称（向きが無い）。どちらが原因かを知りたい。

直感：「A の過去が、B の未来の”B自身の過去では説明できない部分”を、どれだけ当てられるか」。当てられれば $A \rightarrow B$ の情報の流れがある。

式（考え方）： $T(X \rightarrow Y) = I(Y_{\text{未来}}; X_{\text{過去}} | Y_{\text{過去}})$ 。Y 自身の過去を条件に入れるのが肝（Y の自己ダイナミクスを差し引いて、X 由来の”新しい”寄与だけを見る）。

本研究：R&K プロセスネットワークの基本量。結合の向きと”特徴ラグ”を出す。

聞かれたら：「A の過去が B の未来を予測する手がかりになるか＝向きのある情報の流れ。Granger 因果の非線形版です。」

4. サロゲート検定・順列検定 — 「偶然でないか」

何のため：測った I や TE が「たまたま」でないかを判定する。

直感：データをシャッフルして関係を壊した”にせデータ”を何百通りも作り、そこでの値の分布（ヌル）を得る。本物の値がそのヌルから大きく外れていれば「偶然でない（有意）」。

式：しきい値 $\Delta = \mu_{ss} + c \cdot \sigma_{ss}$ （ヌルの平均 + c × 標準偏差）。c=2.36 で片側 $\alpha=0.01$ 。気候相関では「年をシャッフルして相関を作り直す」順列検定で p 値を出した。

本研究：すべての「有意」判定の土台。ヒストグラム推定のバイアスも、同じシャッフルデータが同じバイアスを持つので、ヌルと比べれば自動でキャンセルされる（重要）。

聞かれたら：「データを崩したにせデータと比べて、本物が飛び抜けていれば有意、と判定します。」

5. 多重比較補正 — 「たくさん検定すると偽陽性が増える」

何のため：36 個のラグ × 多数のペアを検定すると、 $\alpha=1\%$ でも「どれかは偶然当たる」。

直感：サイコロを 36 回振れば、 $1/100$ の目も何回か出る。1回の検定の α を守っても、**全体では 偽陽性が $1-(0.99)^{36} \approx 30\%$ に膨らむ。**

対策（本研究）：`peak_min_run=2` = 「2つ以上の連続したラグで有意」を要求。本物の情報流は 時間的に連続した帯として出るが、偶然の偽陽性は単発。これで単発の偽物を落とす。

聞かれたら：「何度も検定すると偶然の当たりが増えるので、“連続して有意”を条件にして偽陽性を 抑えました。」

6. 推定のバイアスと補正（Miller-Madow / KNN）

何のため：情報量を有限のデータから推定すると、系統的にズレる（バイアス）。

直感（次元の呪い）：11 段階に区切った 3 変数の同時分布は $11^3=1331$ マス。データ 3000 点だと 1 マス 2 点でスカスカ。スカスカだと情報量が**過大に出る**（見かけの結合）。

対策：- **Miller-Madow 補正**：主要なバイアス項（使ったマス数-1）/（2×データ数）を差し引く。- **サロゲート比（#4）**：同じスカスカ具合のにせデータと比べればバイアスが相殺。- **KNN（KSG）推定**：マスに区切らず「k 番目に近い点までの距離」で密度を測る。ビンのスカスカを 避けられる。PCMCI の非線形版（CMIknn）の中身。ただし計算が重い（本研究で 5 日かかった正体）。

本研究：「情報量が 0 でない＝結合」ではない、と繰り返し戒めた核心。負の drop や負の Ω を “発見”と誤読しないための鍵。

聞かれたら：「少ないデータだと情報量が過大に出るので、バイアス補正とにせデータ比較で慎重に 判定しています。」

7. PCMCI — 「多変量の因果を描く」

何のため：ペアごとの関係は共通原因や間接経路で偽装される。**全変数を同時に考えた本当の因果** の骨格が欲しい。

直感：2 段階。1. **条件選択（PC）**：各変数について「その未来を説明する候補（親）」を、他の変数を条件に入れ ながら絞る。無関係なものを落とす。2. **MCI 検定**：残った候補それぞれを、**両者の親をすべて条件に入れて**独立性を検定。共通原因・間接経路・自己相関の影響を除く。

これで「 $X \rightarrow Y$ が、他のすべてを考えても残る直接の因果か」を判定し、**有向グラフ**を得る。独立性検定は線形（ParCorr, 速い）と非線形（CMIknn, 重い）を選べる。

本研究：フラックス同士の”同期”が因果として消え、放射→気候・光合成→炭素の疎な骨格が残った（図3）。線形の偽陽性（放射への逆向き）は非線形版で消えて、アーティファクトと確認。

聞かれたら：「全変数の過去を条件に入れて、共通原因や間接経路を除いた”本当の因果の矢印”を 残す手法です。地球科学の時系列因果推定の標準です（Runge 2019）。」

8. PID（部分情報分解） — 「冗長／固有／相乗」

何のため：「2つの源 X, Z が目標 Y について持つ情報」を、質で分ける。

直感（暗証番号の比喻）： - 冗長 R : X と Z が同じ情報のコピーを持つ（両方が Y について同じことを教える）。 - 固有 U : 片方だけが持つ独自の情報。 - 相乗 S : 2つ揃って初めて分かる情報（暗証番号は1桁ずつでは無意味）。

式（考え方）： $I(Y; X, Z) = R + U_X + U_Z + S$ 。冗長 R をどう定義するかに流儀があり、本研究は Williams-Beer の $I_{\min}$ を使った（ただし冗長を過大評価しうる、という既知の弱点あり → #9 で較正）。

本研究：見かけの結合を「放射との冗長（＝共通駆動の影）」「固有（＝直接結合）」に分けた（図2）。

聞かれたら：「共有情報を、コピー（冗長）・独自（固有）・組でしか出ない（相乗）に分けます。」

9. 相互作用情報 と 0-information — 「測度によらず・系全体で相乗を測る」

何のため：PID の相乗は”冗長の定義”に依存する。定義によらない相乗の測り方が欲しい。さらに 2変数でなくサブシステム全体で測りたい。

直感： - 相互作用情報 $II = I(Y; X) + I(Y; Z) - I(Y; X, Z)$ 。PID の測度に依らない不変量。 $II > 0$ なら正味冗長、 $II < 0$ なら正味相乗。これで「相乗は測度の産物では」という疑いを晴らせる。 - 0-information Ω (Rosas 2019) : これを N 変数へ一般化。サブシステム全体が冗長支配 ($\Omega > 0$) か相乗支配 ($\Omega < 0$) かを 1 数値で判定。

式： $\Omega = (n-2)H(\text{全体}) + \sum [H(\text{単独 } i) - H(i \text{ を除いた残り})]$ 。エントロピーだけで計算できる。

本研究：「土壌-呼吸系は相乗支配か？」を測り、森林で相乗・水田で崩壊を示した（図5）。4 変数で次元の呪いが出るので、粗いビン+Miller-Madow+シャッフルヌルの z で慎重に判定。

聞かれたら：「サブシステム全体が、冗長（共通駆動）で回るか相乗（組でしか出ない）で回るかを、1つの数値で測る新しい手法（2019年）です。」

10. Spearman 相関 と 順位検定 p 値 — 「気候との単調な関係」

何のため：「結合の強さ」が「気候ストレス（VPD など）」と一緒に増減するかを測る。

直感：Spearman は**順位に直した相関**。直線でなくても「単調に増える／減る」を捉える。外れ値に強い。有意性は年をシャッフルする順位検定で p 値を出す（#4 と同じ発想）。

本研究：「乾燥（高 VPD）年ほど $I(R_g; GPP)$ が弱い」を r と p で示した（図1、森林 $p=0.001$ ）。

聞かれたら：「順位で見る相関で、単調な関係を外れ値に強く測れます。有意性は順位検定です。」

まとめ — 手法の”流れ”を一言で

情報量で関係を測り (1,2) → 向きを Transfer Entropy で (3) → 偶然でないか検定し (4,5) → バイアスを直し (6) → 共通原因を差し引き (7) → 多変量の因果を PCMCi で描き (7) → 共有情報を冗長・固有・相乗に分解し (8,9) → 気候との関係を相関で測る (10)。

各手法は「前の手法の限界（共通原因の交絡、推定バイアス、測度依存…）を潰すため」に足された。この”一段ずつ厳密にした流れ”そのものが、本研究の方法論的な背骨。

発表で全部は要らない。相互情報量・共通原因の条件付け・PID/0-information の 3 つを、それぞれ比喻（相関の非線形版／太陽と影／暗証番号）で言えれば十分伝わる。