

学習ガイド — この研究を 100% 理解するための知識マップとプロンプト設計

本研究（JapanFlux2024 への Ruddell & Kumar 型プロセスネットワーク解析 + 共通駆動条件付け + PCMCII 因果ネットワーク）を根本から理解するために必要な知識を、**依存順**に並べ、各項目を **あなたのコード/判断のどこに現れるかに紐づけた**。後半に、教科書データベースを持つ AI から **オフライン保存**できる深い解説を効率よく引き出すためのプロンプト設計を置く。

Part 1. 知識マップ（依存順の学習シラバス）

下の Tier は前提が下から積み上がる。Tier 1→7 の順で学ぶと手戻りが少ない。各項目末尾の → は本研究での出現箇所。

Tier 0 — 数学の土台

- 確率変数、同時分布 $p(x, y)$ 、周辺分布、**条件付き分布** $p(y|x)$ 、期待値、独立性
- 対数と情報の単位: **nat（自然対数）** と bit ($\log_2$)、 $H = -\sum p \ln p \rightarrow$ `information_theory.py` は nat
- 総和・ヒストグラム・度数の基本 $\rightarrow$ `np.bincount` による同時分布推定

Tier 1 — 情報理論コア $\rightarrow$ `information_theory.py`

- Shannon エントロピー** $H(X)$ 、同時エントロピー $H(X, Y)$ 、条件付きエントロピー $H(Y|X)$
- 相互情報量** $I(X; Y) = H(X) + H(Y) - H(X, Y)$ 。対称・非負・「共有情報」の意味 $\rightarrow$ `mutual_information_indices`
- 条件付き相互情報量** $I(X; Y|Z) = H(X, Z) + H(Y, Z) - H(Z) - H(X, Y, Z) \rightarrow$ `conditional_mutual_information_indices`
- チェインルール、データ処理不等式、KL ダイバージェンス
- 正規化: $I' = I / \log(m)$ (%表示の根拠) $\rightarrow$ `config.log_m`

Tier 2 — 有限標本でのエントロピー推定 $\rightarrow$ `m=11` ビン, バイアス floor

- プラグイン（ヒストグラム）推定と正バイアス（なぜ標本が少ないと I/TE が過大に出るか）
- 次元の呪い: `m=11` の 3 次元同時分布 = $11^3=1331$ セル、`n≈1500` で 1 セル 1 点 $\rightarrow$ TE floor, 負の drop
- Miller-Madow 補正** $+(K-1)/(2N) \rightarrow$ `_entropy_of_indices(correct=True)`
- KSG (Kraskov-Stögbauer-Grassberger) / KNN 推定**（ビン無し、小標本に強い） $\rightarrow$ 次段階 `CMiknn` の中身
- カーネル推定、適応ビン、記号（順序）エントロピー

Tier 3 — 情報流と Transfer Entropy → `information_theory.py`, `network.py`

- **Transfer Entropy** (Schreiber 2000) : $T(X \rightarrow Y) = I(Y_t ; X_{\text{past}} | Y_{\text{past}})$ 。方向性・非対称性
- **Knuth 2005 形** (R&K 式5) : $T = H(X_{\{t-\tau\}}, Y_{\{t-1\}}) + H(Y_t, Y_{\{t-1\}}) - H(Y_{\{t-1\}}) - H(X_{\{t-\tau\}}, Y_t, Y_{\{t-1\}})$ → `transfer_entropy_indices`
- **TE = 条件付き MI**、Gaussian で **Granger 因果と等価** (Barnett 2009)
- **R&K 2009 プロセスネットワーク**: 11 変数、5 日前方窓アノマリ、固定ビン、結合分類 (type 1 sync / 2 feedback / 3 forcing / 4 uncoupled)、 $T_z = T/I$ の比 → `classify_coupling`, `build_network`
- 特徴ラグ τ' 、ラグ走査曲線 $T(\tau)$ → `first_significant_peak`, `te_lag_curve`
- **発展**: Goodwell & Kumar 2017 **TIPNets** と **PID** (部分情報分解: 冗長/固有/相乗) (Williams & Beer 2010) — 「なぜ同期支配か (冗長性が相乗か)」を分解する、R&K の直系後継

Tier 4 — 有意性検定と多重比較 → サロゲート, `peak_min_run`

- 仮説検定、p 値、ヌル分布の考え方
- **サロゲートデータ法**: シャッフル置換 (時間結合を壊す)、**層内置換** ((X, Z) を保ち $X-Y|Z$ だけ壊す = 条件独立ヌル)、block bootstrap、IAAFT → `surrogate_te_stats`, `surrogate_cmi_stats`
- しきい値 $\Delta = \mu_{ss} + c \cdot \sigma_{ss}$, $c=2.36$ が $\alpha=0.01$ 片側に対応する理由 (正規近似) → `config.sig_c`
- **多重比較問題**: 36 ラグ走査で $\text{FWER} = 1 - (1 - \alpha)^{36} \approx 30\%$ 、Bonferroni / FDR、「連続有意帯を要求」する経験的補正 → `peak_min_run`

Tier 5 — 時系列の因果推論 → `condition_driver.py`, `causal_network.py`

- **交絡 (confounding)・共通駆動・連鎖・合流点 (collider)**、DAG、d 分離 — なぜペアワイズ相関/MI が偽の結合を生むか
- **条件付けで共通駆動を除く原理** → $I(X;Y|R_g)$ の drop 診断
- 多変量/条件付き **Granger 因果** (VAR)
- **PCMCI / PCMCI+** (Runge et al. 2019) : PC 条件選択 + **MCI (Momentary Conditional Independence)**、自己相関への頑健性、独立性検定の選択 (**ParCorr 線形** vs **CMiknn 非線形/KNN** vs GPDC) → `run_pcmci`
- **仮定**: 因果十分性 (未観測交絡なし)、定常性、忠実性 (faithfulness)、マルコフ性 — 破れると何が起きるか (例: R_g への逆向き偽リンク)
- **代替**: 収束クロスマッピング **CCM** (Sugihara 2012, Takens 埋め込み) — TE/Granger と因果の定義が違う裏取り

Tier 6 — 時系列解析の基礎 → アノマリ, 定常性

- 定常性、自己相関関数、スペクトル解析、ウェーブレットコヒーレンス (同期の帯域を見る)
- **日周期の除去** (なぜ 5 日前方窓アノマリか)、季節性 → `_forward_window_anomaly`
- 埋め込み・ラグ・欠測 (listwise deletion, gap 跨ぎ) → `gap_guard`, `step_index`

Tier 7 — フラックス／生態水文のドメイン知識 → 変数の意味, 解釈

- 渦相関法 (eddy covariance) の基礎、エネルギー収支 ($R_n = H + LE + G$)
- 11 変数の物理: $SW_IN(R_g)$, TA , VPD , TS , $SWC(\theta)$, $H(\gamma H)$, $LE(\gamma LE)$, NEE , $GPP(GEP)$, $RECO(GER)$
- 炭素フラックス分割: $NEE = RECO - GPP$ 、昼間法(DT, Lasslop)/夜間法(NT, Reichstein)、 u^* フィルタ、 VUT/CUT 、`_vUT` 命名 → `sites.DEFAULT_VAR_MAP`
- ギャップフィル (MDS: marginal distribution sampling) と QC フラグ — なぜ I が膨らむ恐れ → FINDINGS の caveat
- 陸面-大気結合、蒸発散、土壌水分-温度-呼吸の関係、気孔・光合成の生理
- サイト生態の違い: 冷温帯落葉樹林 / 水田 (湛水管理) / 湿原 (水位一定) → 3 サイト対比の解釈

Part 2. 効率的に学ぶためのプロンプト設計

教科書 DB を持つ AI から「深い・正確・オフライン保存できる」解説を引き出すコツ。

2.1 良いプロンプトの 7 原則

1. 1 プロンプト 1 概念 (詰め込むと浅くなる)。Tier の 1 項目ずつ。
2. 自分の前提を渡す (現在の理解度・ゴール) → AI が深さを校正できる。
3. 出力契約を明示: 構成・深さ・記法・形式・長さ・引用。
4. 順序を指定: 直感 → 定義 → 数式 → 小さな数値例 → **本研究への接続** → 落とし穴 → 自己テスト。
5. オフライン形式: 「1 つの自己完結した Markdown、数式は LaTeX、外部リンク不要」。
6. 出典要求: 教科書名・章・式番号を明記させ、**標準と本研究の逸脱点**を指摘させる。
7. 反復: 曖昧に残った箇所だけ深掘りする追撃プロンプトを用意。

2.2 マスターテンプレート (コピーして各トピックに使う)

あなたは情報理論・因果推論・生態水文学に精通した教師です。手元の教科書データベース (Cover & Thomas, MacKay, Bossomaier, Runge/Spirites/Pearl, Aubinet 等) を根拠に解説してください。

私の背景

- 専攻/レベル: <例: 学部4年、微積と線形代数は可、測度論は未修>
- 既知: <例: 相互情報量の定義は分かる>
- ゴール: <例: 自分の PCMCi 解析で「共通駆動を条件付ける」原理を説明できるようになる>

学びたいトピック

<例: 条件付き相互情報量 $I(X;Y|Z)$ と、それが共通駆動をどう除くか>

本研究の文脈 (なぜ学ぶか)

30分値フラックス11変数に Ruddell&Kumar 型 TE と PCMCi を適用。放射 R_g が全変数を共通駆動する

ため、ペアワイズ I が偽の同期を生む。 $I(X;Y|Rg)$ の減少率で共通駆動を切り分けている。

出力への要求（厳守）

1. 直感（比喩1つ）→ 2. 正式な定義（LaTeX、記法表つき）→ 3. 主要性質と証明の要点
 - 4. 手計算できる最小の数値例（3値程度、途中式つき）→ 5. 本研究の該当処理への接続（上の文脈に具体的に結びつける）→ 6. よくある誤解・落とし穴 3つ → 7. 理解度自己テスト（設問5・解答つき）→ 8. 出典（教科書名・章・式番号）と、本研究の手法が標準からずれる点。
- 形式：1つの自己完結した Markdown 文書。外部リンク・画像なしで完結。数式は $\$...\$ / \$\$...\$$ 。
 - 深さ：学部上級～院初級。要点を省かず、ただし冗長な前置きはなし。
 - 不確かな点は「教科書での扱いが分かれる」と明示。憶測で断定しない。

2.3 そのまま使える記入済み例（重要トピック 3 本）

(a) 推定バイアスと Miller-Madow

（マスターテンプレートの背景・形式はそのまま）

学びたいトピック

ヒストグラム(プラグイン)エントロピー推定の有限標本バイアスと、Miller-Madow 補正。
なぜ次元が増える(2D MI→3D 条件付きMI)とバイアスが増え、条件付けで見かけ上MIが増える
「負の drop」が起きるのか。KSG(KNN)推定がなぜこれを緩和するか。

特に答えてほしい問い

- プラグイン H の期待バイアスは $-(K-1)/(2N)$ 程度、という式の導出の要点
- $m=11$, 3次元, $N \approx 1500$ で具体的にどれくらいのバイアスか概算
- Miller-Madow が主要項をどう打ち消すか、限界は何か
- KSG が次元の呪いをどう回避するか（ k 近傍の考え方）

(b) Transfer Entropy と Granger・条件付きMI の関係

学びたいトピック

Transfer Entropy の定義(Schreiber)と Knuth 形($R\&K$ 式5)の同値性。TE が条件付き相互情報
 $I(Y_t; X_{\{t-\tau\}} | Y_{\{t-1\}})$ であること。Gaussian で Granger 因果と等価(Barnett 2009)である理由。

特に答えてほしい問い

- Knuth 形の4エントロピー項が $I(Y_t; X_{\{t-\tau\}} | Y_{\{t-1\}})$ に一致する代数展開
- なぜ $Y_{\{t-1\}}$ で条件付けるのか（自己ダイナミクスの除去）
- $T_z = T/I$ が「forcing 対 feedback」を分ける情報理論的意味
- TE の「情報流」を因果と呼べる条件と、呼べない反例

(c) PCMCI+ と共通駆動・多重比較

学びたいトピック

PCMCI+ の2段階(PC条件選択 + MCI)。共通駆動と間接経路をどう除くか。自己相関がなぜ
偽リンクを生み、MCI がどう対処するか。ParCorr(線形)と CMIknn(非線形KNN)の違い。
因果十分性・定常性・忠実性の仮定が破れたとき何が起きるか(例:放射Rgへの逆向き偽リンク)。

特に答えてほしい問い

- d 分離と条件付き独立の対応。共通駆動 Rg を条件集合に入れると偽リンクが消える理屈
- MCI が Bonferroni より検出力を保てる理由

- CMiknn のシャッフル検定が重い理由(計算量)と、knn/sig_samples の役割
- 我々の「逆向き Rg リンク」偽陽性の原因候補（線形近似 / 有限標本 / faithfulness 違反）

2.4 反復（深掘り）プロンプトの型

前回の「<トピック>」の説明のうち、<箇所> がまだ腑に落ちません。
具体的には <疑問>。別の比喻と、<例: 2変数の具体数値> で追加説明してください。
また私の理解「<自分の言葉での要約>」の誤りを指摘してください。

2.5 オフライン保存の実務

- 各回答を `study/<tier>_<topic>.md` として保存（この Markdown 群がオフライン教材になる）。
- 冒頭に**記法表**と**用語集**を作らせ、全ファイルで記法を統一させる（「以降この記法で」と固定）。
- 最後に **1 枚の要約カード**（定義・式・落とし穴・本研究での意味）を作らせると復習が速い。
- 数式が多い場合は「Pandoc で PDF 化できる純粋 Markdown で」と指定。

Part 3. 学習順序と自己確認

1. **Tier 1→2→4** を先に（情報理論コア・推定バイアス・有意性）。ここが本研究の推定と検定の心臓部。
2. 次に **Tier 3**（TE と R&K）。1,2,4 が入っていれば式5の意味が腑に落ちる。
3. **Tier 5**（因果推論・PCMRI）。ここが「ペアワイズの限界→条件付け→多変量因果」という本研究の物語の核。
4. **Tier 6,7** は並行で可（時系列・ドメイン）。特に Tier 7 は解釈（3 サイト対比）に必須。
5. **自己確認**: 各 Tier 後に、対応するコード（下表）を読んで「式⇄実装」を照合する。読めれば理解できている。

概念	読むコード
エントロピー/MI/CMI/TE	<code>information_theory.py</code>
バイアス補正	<code>_entropy_of_indices(correct=True)</code>
サロゲート・多重比較	<code>surrogate*_stats, network.first_significant_peak(min_run)</code>
結合分類 Tz	<code>network.classify_coupling</code>
共通駆動条件付け	<code>condition_driver.py</code>
多変量因果	<code>causal_network.py</code>
アノマリ・欠測	<code>preprocess.py</code>
ドメイン(変数/分割)	<code>sites.py, config.RK_VARS</code>

Part 4. 標準教科書・原著 (AI に根拠として指定する用)

情報理論 - Cover & Thomas, *Elements of Information Theory* — エントロピー/MI/チェインルール/DPI の定番 - MacKay, *Information Theory, Inference, and Learning Algorithms* — 直感重視、無料PDF あり

Transfer Entropy / 情報流 - Bossomaier et al., *An Introduction to Transfer Entropy* — TE の教科書 - Schreiber 2000 (PRL); Knuth 2005; **Ruddell & Kumar 2009 (WRR)** (本研究の原著) - **Goodwell & Kumar 2017 (WRR) TIPNets**; Williams & Beer 2010 (PID) - Barnett, Barrett & Seth 2009 (PRL) — TE+Granger 等価 - Kraskov, Stögbauer & Grassberger 2004 (PRE) — KSG 推定

因果推論 - Pearl, *Causality*; Peters, Janzing & Schölkopf, *Elements of Causal Inference* (無料 PDF) - Spirtes, Glymour & Scheines, *Causation, Prediction, and Search* — PC アルゴリズム - **Runge et al. 2019 (Science Advances / Nature Comms) PCMCi**; Runge 2018 (総説) - Sugihara et al. 2012 (Science) — CCM

時系列 - Hamilton, *Time Series Analysis*; Shumway & Stoffer, *Time Series Analysis and Its Applications*

渦相関・生態水文 - Aubinet, Vesala & Papale (eds.), *Eddy Covariance: A Practical Guide* - Reichstein et al. 2005 (NT 分割); Lasslop et al. 2010 (DT 分割); Pastorello et al. 2020 (FLUXNET2015/ONEflux) - Bonan, *Ecological Climatology*; Monteith & Unsworth, *Principles of Environmental Physics*; Brutsaert, *Hydrology*

補足: この学習ガイドは本研究のコードと結論 (同期支配 / 共通駆動交絡 / 2 群分離 / PCMCi 有向網) に対応づけてある。各 Tier を学んだら FINDINGS.md の該当主張を自分の言葉で再導出できるか試すと、理解の穴が可視化できる。