

研究全体の理解ガイドー 過程と結果を追うための知識

この文書は、本研究（JapanFlux2024 への情報理論プロセスネットワーク解析）の全過程を一本の物語として理解するためのもの。各段階について「なぜやったか／手法の核／理解に必要な概念／得た結果／落とし穴と訂正」を並べる。

- 一般的な知識シラバスと学習プロンプト → [STUDY GUIDE.md](#)
- 結果の簡潔な記録（追記 1-7） → [FINDINGS.md](#)
- 本書 → その 2 つを橋渡しする「過程と結果の理解」

記号：I=相互情報，TE=transfer entropy，CMI=条件付き相互情報，PID=部分情報分解， Ω =0-information。%表記は特記なき限り $I/\log(m)$ 正規化。

0. 一目でわかる全体アーク

本研究の背骨は「素朴な情報流ネットワークを、段階的に厳密化して”本当の構造”を取り出す」。各段階は前段の限界を潰すために足された。

段階	問い	手法	主な結果	状態
1	変数間の情報流は？	R&K の TE ネットワーク	「同期支配」に見える	交絡の疑い
2	偽陽性では？	多重比較補正 (peak_min_run)	単発クロスを除去	補正済
3	推定は正しい？	Miller-Madow・サロゲート	バイアス floor を較正	補正済
4	共通駆動の影では？	条件付き MI (Rg 条件付け)	同期は放射の冗長／2 群分離	確定
5	多変数の因果は？	PCMCI (線形＋非線形)	疎な有向骨格・偽陽性消滅	確定
6	単年の偶然では？	複数年ロバスト性	普遍コア安定 (34 site-yr)	確定
7	gap-fill の産物では？	QC 制限再解析	構造は実測でも再現	確定
8	同期の中身は？	PID＋較正 (冗長/固有/相乗)	フラックス=冗長，熱=固有+相乗	確定
9	気候で変わる？	気候応答＋順列検定	乾燥で光合成が脱結合 (有意)	確定
10	高次の構造は？	0-information＋多年	森林で呼吸相乗，水田で崩壊	一部訂正

通底する教訓：データを増やして素朴な手法を使うと「自信を持って間違える」。段階的な 厳密化と自己批評（特に段階 6・10）が、過大主張を削って頑健な核を残した。

1. 出発点 — 問いとデータ

問い：生態系の気象・エネルギー・炭素変数（11 個）は互いにどう情報を流し合うか。誰が 誰を駆動し、どの結合が実体的で、生態系や気候でどう違うか。

データ：JapanFlux2024（2025 公開）の 30 分値。3 生態系 = 落葉樹林 JP-Tak / 水田 JP-Mse / 湿原 JP-BBY。11 変数（R&K Table 2）：放射 R_g ・気温 T_a ・飽差 VPD ・地温 T_s ・降水 P ・土壌水分 θ ・顕熱 γH ・潜熱 γLE ・呼吸 GER ・正味交換 NEE ・光合成 GEP 。

前処理（[preprocess.py](#)）： - 5 日前方窓アノマリ：各時刻から「同時刻帯の直後 5 日平均」を引く。→ 日周期を除去し、日々の天候変動（＝情報が流れる部分）だけを残す。これをしないと、全変数が太陽の日周期で一斉に動くだけの自明な同期を見てしまう。 - **listwise deletion**：11 変数が全て有効な時刻だけ残す。 - 理解に必要な概念：定常性・アノマリ・欠測処理（STUDY_GUIDE Tier 6）。

2. 情報理論の言葉（全段階の共通土台）

理解に必要な最小限（詳細は STUDY_GUIDE Tier 1-2）：

- ・ **エントロピー** $H(X) = -\sum p \log p$ ：不確かさの量（nat）。
- ・ **相互情報** $I(X;Y) = H(X)+H(Y)-H(X,Y)$ ： X と Y が共有する情報。対称・非負。
- ・ **条件付き相互情報** $I(X;Y|Z) = H(X,Z)+H(Y,Z)-H(Z)-H(X,Y,Z)$ ： Z を知った上で残る X - Y の依存。
- ・ **Transfer entropy** $T(X \rightarrow Y) = I(Y_t ; X_{\{t-\tau\}} | Y_{\{t-1\}})$ ： Y の自分の過去を差し引いた上で、 X の過去が Y の未来に与える情報＝有向な情報流。
- ・ 推定は**固定ビン $m=11$ のヒストグラム**（プラグイン推定）。多次元は混合基数エンコード＋`np.bincount`。すべて [information theory.py](#)。

最重要の落とし穴（段階 3・8・10 で何度も戻る）：高次元ヒストは有限標本で正バイアスを持つ。3 変数（ $11^3=1331$ セル）を ~ 3000 点で埋めると 1 セル ~ 2 点で、 I や TE が過大に出る「floor」が生じる。対策は（a）絶対値でなく**サロゲート（シャッフル）比**で判定、（b）**Miller-Madow 補正** $+(K-1)/(2N)$ 。これが分らないと段階 8・10 の「負の値」を誤読する。

3. 各段階の詳細

段階 1: R&K プロセスネットワーク（[network.py](#)）

- ・ **手法**：全ペアで TE のラグ曲線 $T(\tau)$ を作り、shuffled surrogate のしきい値 $\Delta = \mu_{ss} + c \cdot \sigma_{ss}$ （ $c=2.36 \approx \alpha=0.01$ 片側）を超える有意ピークを探す。結合を Table 1 の 4 型に分類：1 同期 / 2 フィードバック / 3 強制 / 4 無結合。分岐は $T_z = T/I$ (>1 なら強制)。
- ・ **必要知識**： TE ，サロゲート検定，仮説検定（Tier 3-4）。
- ・ **結果**：3 生態系すべてで見かけ上「同期支配（type 1）」。有向流（type 2）は放射・生産・乱流フラックス間の 0.5h に限られ、**forcing はほぼ無い**。

- 落とし穴：この「同期支配」は後段で**共通駆動の交絡**と判明する（＝額面通り信じてはいけない）。

段階 2: 多重比較（[network.py](#) peak_min_run）

- 問題：36 ラグを走査し「どれか 1 本でも有意なら結合」とすると、族全体の偽陽性率が $1-(0.99)^{36} \approx 30\%$ に膨らむ。
- 対策：peak_min_run=2（有意ピークが長さ 2 以上の連続有意帯に属することを要求）。真の情報流は時間的に連続した帯として出るが、iid の偽陽性は単発。
- 必要知識：家族単位誤り率 FWER, 多重比較 (Tier 4)。
- 実証：単月・min_run=1 で出た $P \rightarrow \gamma H$ の”強制” (6h) は min_run=2 で消えた＝教科書的偽陽性。

段階 3: 推定器の較正 (Miller-Madow・サロゲート)

- 問題：m=11 の 3D TE は正バイアス floor (~ 0.15 nat) を持ち、絶対値 0 と比較できない。
- 対策：有意性は floor 込みのサロゲート分布に対して判定。次元の異なる量を比べるとき（段階 8 の 2D I と 3D CMI）は Miller-Madow 補正でバイアスを揃える。
- 理解の鍵：「TE が 0 でない＝結合」ではない。サロゲート比で見る。

段階 4: 共通駆動の条件付け（[condition_driver.py](#)）－ 転換点

- 問い：「同期」の何割が、放射 Rg が全変数を同時駆動する**共通駆動の影**か？
- 手法：各ペアで $I(X;Y)$ と $I(X;Y|Rg)$ を比較。減少率 $drop=1-CMI/MI$ が大きいほど Rg で説明される。条件独立ヌルは Z の層内で X を置換（(X,Z) を保ち $X-Y|Z$ だけ壊す）。
- 必要知識：条件付き独立, 交絡・共通駆動・d 分離 (Tier 5)。
- 結果：「同期」は 2 群に割れる。群 A ($\gamma H, \gamma LE, GEP, NEE$) は Rg 条件付けで 60-90% 減少＝**共通駆動の影**。群 B (Ta, Ts, GER, VPD の熱系) は残存＝**放射独立の直接結合**。
- 落とし穴：ピンで連続 Rg を条件付けると残差が漏れ、弱ペアで $CMI > MI$ (負の drop)＝次元 バイアス。→ Miller-Madow で緩和、信頼できるのは高 I% ペアのみ。

段階 5: 多変量因果 PCMCI（[causal_network.py](#)）

- 問い：全変数の過去で条件付けたら、真の有向因果骨格は何か？
- 手法：PCMCI+ (Runge 2019)。PC 条件選択+MCI (Momentary Conditional Independence) で 共通駆動・間接経路・自己相関を除く。独立性検定は ParCorr (線形・秒) と CMiknn (非線形 KNN・完全版は 3 サイト 120 時間)。
- 必要知識：因果探索, PC アルゴリズム, 条件付き独立検定の選択, 因果十分性/定常性/忠実性 の仮定 (Tier 5)。
- 結果：フラックス相互「同期」は有向リンクとして消滅。残る骨格は物理コアのみ： $Rg \rightarrow \gamma LE, GEP \rightarrow NEE, Ta \rightarrow Ts$ + サイト別ハブ。非線形 CMiknn は逆向き Rg 偽陽性 (線形のアーティファクト) まで消した。段階 4 の結論を多変量で裏付け。

段階 6: 複数年ロバスト性 ([run_robustness.py](#))

- 問い: 骨格は単年の偶然でなく安定特性か?
- 手法: 各サイトの健全全年で PCMCi を回し、有向リンクの出現頻度を集計。
- 結果: 普遍コア (GEP→NEE, Rg→γLE, Rg→VPD) が 3 サイト全部で高頻度、計 34 site-year で安定。逆向き Rg は散発的 (=偽陽性の裏付け)。時間・空間の両軸でロバスト。

段階 7: QC 制限再解析 ([qc_scan.py](#), config.qc_max)

- 問い: 「同期」は gap-fill (欠測補完) が I を人工的に膨らませた産物では?
- 手法: $QC \leq 1$ (実測+良質補完のみ、中~低品質補完を除外) で再解析。feasibility は QC 被覆スキャンで事前確認 (QC=0 は降水と炭素の欠測で不能、QC≤1 は n≈1900-2900 で可)。
- 結果: 3 サイトで 2 群分離が保たれ、MI 水準は一樣に下らない (下がるも上がるも混在)。 → gap-fill 由来の I 膨張は否定。最大の方法論的留保を解消。

段階 8: 部分情報分解 PID ([pid_analysis.py](#))

- 問い: 同期の中身は「冗長 (共有)」か「相乗 (創発)」か?
- 手法: Williams-Beer の $I_{\min}$ PID。 $I(Y; Rg, X)$ を R (Rg と冗長) / U_X (X 固有) / U_{Rg} / S (相乗) に分解。
- 必要知識: 特定情報 $i(s; A)$, 冗長性測度の定義 (Tier 3)。
- 結果: フラックス・炭素は Rg 冗長 ($R/I \approx 100\%$)、熱・土壌・呼吸は 固有+相乗。
- 校正 (重要): $I_{\min}$ は冗長を過大評価しうる+S の I_{joint} は 3D バイアス。測度不変な相互作用情報 $II = I1 + I2 - I_{\text{joint}}$ ($II < 0$ が正味相乗) を Miller-Madow つきで計算。 → 土壌・熱系の相乗は測度・バイアスの両方に頑健。GEP←NEE の見かけの相乗は冗長に訂正。

段階 9: 気候ストレス応答 ([climate_response.py](#)) — 動的な新規性

- 問い: 情報構造は気候ストレスで組み変わるか? (静的地図でなく動的応答)
- 仮説: 乾燥 (高 VPD・低 θ) で気孔が閉じ、光合成が光律速でなくなる → $I(Rg; GPP)$ が弱まる。
- 手法: 健全全年で、生の平均ストレス指標 (VPD, θ , Ta) と結合強度 I の Spearman 相関。有意性は順列検定 (年ラベルをシャッフル) で p 値。
- 結果: 森林 $r = -0.68$, $p = 0.001$ / 水田 $r = -0.79$, $p = 0.028$ で有意。2003 冷夏で結合最大・2018 猛暑で最小と実イベントで固定。水田は θ が湛水で一定なので大気ストレス (VPD) 由来と判明 (土壌ストレスと分離)。湿原 $n=5$ ・逆符号で非支持 (飽水で水ストレス無し)。

段階 10: 高次情報構造 0-information ([oinfo_analysis.py](#)) — 新手法

- 問い: サブシステム全体が冗長支配か相乗支配か (PID の 2 源→N 変数への一般化)。
- 手法: 0-information $\Omega = (n-2)H(X) + \sum [H(X_i) - H(X_{-i})] = TC - DTC$ (Rosas 2019)。 $\Omega > 0$ 冗長支配, $\Omega < 0$ 相乗支配。4 変数は疎なので粗ピン $m=6$ +Miller-Madow+シャッフルヌルの z で判定 (絶対 Ω はバイアス込み)。
- 必要知識: 全相関 TC, 双対全相関 DTC, 0-information の符号の意味。
- 単年結果: 呼吸制御 {Rg, Ta, θ , GER} が森林・湿原で相乗、フラックス系は冗長。

- 多年による自己訂正（重要）：全年で再計算すると 森林の呼吸相乗は 19/21 年で安定、水田は 0/8 で相乗なし = 森林 vs 管理水田の対比が頑健。一方「湿原で最強の相乗」は 2015 単年の効果で再現せず、撤回。土壌熱も不安定。→ 多年チェックが過大主張を削り、頑健な核を残した。

4. 横断する 4 つの中心概念

1. 共通駆動の交絡：放射 R_g が全変数を同時駆動するので、ペアワイズの I/TE は偽の結合を生む。条件付け（段階 4）・多変量因果（段階 5）・PID の冗長 R （段階 8）が、それぞれ別角度で「見かけの同期＝共通駆動」を定量化する。
2. 次元の呪いと推定バイアス：高次元ヒストは正バイアス floor を持つ。段階 3・4・8・10 で繰り返して、対策は毎回同じ 3 点＝サロゲート比・Miller-Madow・小集合に絞る。「負の drop」「負の Ω 」を”発見”と誤読しないための鍵。
3. 冗長 vs 固有 vs 相乗：共有情報の質の 3 分類。冗長＝共通駆動、固有＝直接結合、相乗＝組でしか出ない創発。段階 8（2 源 PID）→段階 10（ N 変数 0-info）と深化。測度不変量（ II , Ω の z ）で頑健性を担保する。
4. 静的構造 vs 動的応答：段階 1-8・10 は「どういう構造か」（静的）。段階 9 は「その構造が気候でどう変わるか」（動的）。動的応答が平均フラックスに見えない機能情報を持つ。

5. 最終的に言えること（結果の総合）

頑健な核（多手法・多年・多品質で確定）： - エネルギー・炭素フラックスの見かけの「同期」は、大半が放射 R_g の共通駆動の冗長情報（条件付け・PCMCI・PID の R が一致）。 - 真の因果骨格は疎： $R_g \rightarrow \gamma LE$, $GEP \rightarrow NEE$, $Ta \rightarrow Ts$ + 生態系別ハップ、34 site-year で安定。 - 森林の土壌-呼吸系は高次相乗が安定（19/21 年）、管理水田では相乗が消える（0/8） = 湛水管理が θ を固定して高次相乗を壊す署名。 - 乾燥で光合成が放射から脱結合（森林 $p=0.001$ ・水田 $p=0.028$ 、実気候極端で固定）。

訂正されたもの（自己批評の履歴＝信頼性の担保）： - 「湿原で相乗最強」→ 2015 単年の効果、多年で再現せず、撤回。 - 土壌熱の相乗、 $GEP \leftarrow NEE$ の見かけの相乗 → 不安定/冗長と判明、除外・訂正。

新規性の正直な位置づけ（文献調査済み）： - 手法（R&K, TIPNets, PCMCI, PID, 0-info）はすべて既発表。概念（共通駆動交絡・情報構造の水ストレス応答）も Goodwell et al. 2018 (PNAS) 等が先行。 - 本研究は「発見」でなく「確立手法の、新公開 JapanFlux2024・湿潤モンスーン・管理水田への系統的拡張」+ 0-information という新手法での「管理生態系の高次相乗崩壊」という一点。Goodwell の乾燥・自然サイトに対する湿潤・管理側の補集合。

6. 結果を自分で再導出するための対応表

概念／結果	読む／回すもの
H / I / CMI / TE / PID / 0-info の実装	information_theory.py
前処理（アノマリ・欠測・QC）	preprocess.py , qc_scan.py
同期支配・結合分類	run_site.py , network.py
共通駆動の 2 群分離	condition_driver.py
疎な因果骨格	causal_network.py (parcorr / cmiknn)
34 site-year の安定性	run_robustness.py
gap-fill 懸念の解消	qc_scan.py + --qc-max 1
冗長/固有/相乗+校正	pid_analysis.py (--calibrate)
気候脱結合 + p 値	climate_response.py
高次相乗 + 多年訂正	oinfo_analysis.py (--multiyear)
全結果の記録	FINDINGS.md (追記 1-7)
一般知識と学習プロンプト	STUDY_GUIDE.md

再現の目安: parcorr 系・情報量系は秒～分。cmiknn 完全版のみ数時間～日 (tau_max=6 に絞れば 現実的)。テストは `python -m pytest tests/ -q` (56 件)。

7. 最小用語集

- ・ **アノマリ**: 平均的な日周期からのずれ。天候由来の変動。
- ・ **共通駆動 (common driver)**: 1 つの原因 (Rg) が複数変数を同時に動かすこと。ペアワイズ結合を偽装する。
- ・ **サロゲート**: データをシャッフルして依存を壊した対照。有意性のヌルを作る。
- ・ **floor / バイアス**: 有限標本で情報量が 0 でなく正の下駄を履く現象。
- ・ **Miller-Madow**: エントロピー推定の主要バイアス項 $(K-1)/(2N)$ を差し引く補正。
- ・ **冗長 R / 固有 U / 相乗 S**: 複数源が目標に与える情報の質。共通/独自/組でしか出ない。
- ・ **相互作用情報 II**: $I1+I2-I_{joint}$ 。PID 測度に依らず、正で冗長・負で相乗。
- ・ **0-information Ω** : 系全体の冗長(>0)/相乗(<0)を 1 数値で。TC-DTC。
- ・ **PCMCi**: 全変数の過去で条件付けて因果グラフを推定する手法（自己相関に頑健）。
- ・ **VUT / _vUT / QC**: FLUXNET 由来のフラックス処理（可変 $u*$ 閾値・品質フラグ）。

8. 読むべき原著（優先順）

1. Ruddell & Kumar (2009, WRR) — プロセスネットワークの原著（本研究の土台）。

2. Goodwell & Kumar (2017, WRR) — TIPNets, 冗長/固有/相乗の PID。
3. Goodwell et al. (2018, PNAS) — 情報構造の干ばつ応答（段階 9 の先行研究）。
4. Runge et al. (2019, Nature Comms / Sci Adv) — PCMCi (段階 5)。
5. Williams & Beer (2010) — PID の $I_{\min}$ (段階 8)。
6. Rosas et al. (2019) — 0-information (段階 10)。
7. Kraskov, Stögbauer & Grassberger (2004) — KSG/KNN 推定 (cmiknn の中身)。
8. Cover & Thomas, *Elements of Information Theory* — 情報理論の教科書。

この文書は本研究のコード・結果・自己批評の履歴に対応づけてある。各段階を読んだら、対応するコードを開いて「式⇄実装」を照合し、FINDINGS の該当主張を自分の言葉で再導出できるか試すと、理解の穴が可視化できる。